

Clasificación del Impacto de Noticias Financieras con Naïve Bayes Multinomial

Del titular al nivel de impacto: un flujo de procesamiento de texto en R y el diagnóstico de un conjunto de datos sin señal

Juan Pablo Venegas Padilla • Arie Zalo González
Santiago de la Calleja Jiménez • Juan Pablo Espinosa Maciel

Ingeniería en Ciencia de Datos y Matemáticas, Tecnológico de Monterrey
14 de septiembre de 2026

Resumen. Este trabajo construye un clasificador **naïve Bayes multinomial** que estima el nivel de impacto de una noticia financiera a partir de su titular, sobre un conjunto de 3,024 noticias con evento de mercado, sector, sentimiento e indicadores del índice asociado. La metodología encadena un análisis exploratorio y una limpieza en Python con un flujo de procesamiento de texto en R: tokenización de los titulares, eliminación de palabras vacías, construcción de una matriz dispersa documento–término, recodificación de la variable objetivo a dos clases —impacto alto contra impacto medio o bajo— y ajuste del clasificador con suavizado de Laplace sobre una partición de 80/20. El resultado es un modelo que **no supera a la regla trivial** de predecir siempre la clase mayoritaria: su exactitud queda por debajo de esa línea base, dos de cada tres alertas de impacto alto son falsas y más de la mitad de las noticias realmente relevantes pasan desapercibidas. La explicación no está en el clasificador sino en los datos, y el análisis exploratorio la anticipa: el conjunto contiene apenas 50 titulares distintos repetidos decenas de veces, un mismo titular aparece etiquetado con los tres niveles de impacto, y ni el sentimiento ni los indicadores numéricos discriminan entre niveles. Asignar a cada titular su etiqueta más frecuente acierta solo un 41 %, de modo que el techo de cualquier modelo que use únicamente el texto está fijado de antemano. El aporte del trabajo es doble: un flujo reproducible de clasificación de texto financiero, y el diagnóstico documentado de por qué un conjunto puede impedir el aprendizaje por construcción.

Palabras clave— Naïve Bayes multinomial, clasificación de texto, noticias financieras, bolsa de valores, matriz documento–término, suavizado de Laplace, ruido de etiquetas.

1. Introducción

Que las noticias mueven los mercados es una de las pocas afirmaciones que casi nadie discute en finanzas. Lo que sí se discute es cuánto y en qué dirección, y la evidencia empírica al respecto proviene en buena medida del análisis del texto: Tetlock [1] mostró que el tono pesimista de una columna diaria del *Wall Street Journal* anticipa presión a la baja en los precios y un repunte posterior del volumen, y Loughran y McDonald [2] documentaron que los diccionarios de sentimiento diseñados para textos generales clasifican mal el lenguaje financiero, al punto de que casi tres cuartas partes de las palabras que un diccionario estándar considera negativas no lo son en un informe corporativo.

Si el texto de una noticia contiene información sobre el mercado, la pregunta operativa para quien invierte es más simple que la académica: dado el titular que acaba de publicarse, ¿esta noticia va a mover el índice de forma apreciable o no? Formulada así, es un problema de clasificación de texto, y el clasificador natural para empezar es **naïve Bayes**. Este trabajo lo construye y lo evalúa sobre un conjunto de noticias financieras etiquetadas con su nivel de

impacto.

1.1. Antecedentes y estado del arte

Naïve Bayes es un clasificador probabilístico que estima la probabilidad de cada clase dado el documento suponiendo que las palabras son condicionalmente independientes entre sí una vez fijada la clase. En finanzas tiene un antecedente directo: Antweiler y Frank [3] clasificaron más de un millón y medio de mensajes de foros bursátiles con naïve Bayes y encontraron que, si bien el efecto sobre los rendimientos es económicamente pequeño, el desacuerdo entre mensajes predice volatilidad y volumen. Es decir, el enfoque de bolsa de palabras aplicado a texto financiero no es una curiosidad metodológica sino una herramienta con historial.

En clasificación de texto en general, el modelo multinomial —que representa cada documento por el número de veces que aparece cada término del vocabulario— es la formulación de referencia [4]. McCallum y Nigam [5] compararon sistemáticamente esa formulación contra la alternativa de Bernoulli, que solo registra presencia o ausencia, y concluyeron que la multinomial rinde mejor en vocabularios grandes, que es la situación habitual. Su atractivo persistente es que el supuesto de independencia, que casi nunca se cumple en lenguaje natural, no impide un buen desempeño: Domingos y Pazzani [6] explicaron por qué un clasificador puede acertar la clase aunque sus estimaciones de probabilidad estén sesgadas, ya que para decidir basta con ordenar bien las clases, no con calibrar sus probabilidades.

Hay, sin embargo, un límite que ningún clasificador cruza. Cuando las etiquetas de entrenamiento contienen ruido —cuando ejemplos idénticos aparecen con etiquetas distintas— el desempeño alcanzable está acotado con independencia del algoritmo, y el ruido puede además degradar el aprendizaje más allá de esa cota [7]. Este trabajo termina siendo, en buena medida, un caso de estudio de esa situación.

1.2. Problema y preguntas de investigación

El objeto de estudio es un conjunto de 3,024 noticias financieras en el que cada registro trae el titular, el evento de mercado que lo origina, el índice y el sector afectados, el sentimiento asignado, el cambio porcentual del índice, el volumen operado y una etiqueta de nivel de impacto con tres valores. Las preguntas son tres:

- P1** ¿Puede un clasificador naïve Bayes multinomial distinguir, a partir del titular, las noticias de impacto alto del resto?
- P2** ¿Qué desempeño alcanza frente a la línea base trivial de predecir siempre la clase mayoritaria, y qué significan sus errores para quien tomaría decisiones con él?
- P3** Si el desempeño es bajo, ¿la causa está en el clasificador o en los datos?

1.3. Objetivos

General: implementar y evaluar un flujo completo de clasificación de texto —desde los datos crudos hasta las métricas— que estime el nivel de impacto de una noticia financiera a partir de su titular. **Específicos:** (i) caracterizar el conjunto y decidir de forma explícita el tratamiento de los valores faltantes; (ii) construir la representación de texto que el modelo multinomial requiere; (iii) ajustar el clasificador con suavizado y evaluarlo sobre una partición independiente; (iv) interpretar los errores en términos financieros; y (v) determinar si el desempeño observado es atribuible al modelo o a la estructura de los datos.

1.4. Aportaciones

1. Un **flujo reproducible** de clasificación de texto financiero que va del CSV crudo a las métricas, con la etapa de exploración y limpieza en Python y la de texto y modelado en R, y con cada decisión de tratamiento de faltantes escrita de forma explícita.
2. Un **diagnóstico del conjunto de datos** que precede al modelo y anticipa su resultado: la escasa variedad de titulares, la inconsistencia de las etiquetas y la ausencia de relación entre el nivel de impacto y el resto de las variables.

3. Una **lectura financiera de los errores**, que traduce la precisión y la sensibilidad del clasificador al costo concreto de actuar sobre sus alertas.

2. Metodología

2.1. Arquitectura del flujo de trabajo

El proyecto se divide en dos etapas con lenguajes distintos. La **exploración y limpieza** corre en Python con **pandas** [8] sobre un cuaderno que produce un único archivo intermedio con las columnas útiles y sin valores faltantes. El **procesamiento de texto y el modelado** corren en R [9] sobre dos documentos Quarto: el primero usa **tidyverse** [10] y **tidytext** [11] para tokenizar los titulares y construir la matriz documento–término, y el segundo ajusta el clasificador con el paquete **naivebayes** [12]. La Fig. 1 resume las cinco fases. Todo el código está disponible en <https://github.com/JuanPVenegas13/Wall-Street-Pulse>.




Figura 1: Metodología propuesta, en cinco fases secuenciales.

2.2. Datos y tratamiento de los faltantes

El archivo de origen reúne **3,024 noticias** y 12 columnas, descritas en el diccionario de datos que acompaña al conjunto y resumidas en la Tabla 1. No hay filas duplicadas.

Tabla 1: Las doce columnas del conjunto original y su tratamiento.

Columna	Tipo	Descripción y destino
Headline	texto	Titular de la noticia. Entrada del clasificador.
Impact_Level	categoría	High / Medium / Low. Variable objetivo.
Market_Event	categoría	Evento de mercado que origina la noticia (20 niveles). Se conserva.
Market_Index	categoría	Índice asociado, como S&P 500, DAX o FTSE 100 (18 niveles). Se conserva.
Sector	categoría	Sector afectado (18 niveles). Se conserva.
Sentiment	categoría	Positive / Neutral / Negative. Se conserva.
Index_Change_Percent	float	Cambio porcentual del índice, entre -5 y $+5$. Se conserva.
Trading_Volume	float	Volumen operado en millones. Se conserva.
Date	fecha	Fecha de publicación. Se descarta: el objetivo no es temporal.
Source	texto	Medio que publica (18 niveles). Se descarta.
Related_Company	texto	Empresa mencionada (10 niveles). Se descarta.
News_Url	texto	Enlace de la fuente. Se descarta: no describe la noticia.

Cuatro columnas tienen valores faltantes, todas alrededor del 5 %: el titular en 148 registros (4.89 %), el cambio porcentual en 161 (5.32 %), el sentimiento en 171 (5.65 %) y el enlace en 153 (5.06 %). La decisión sobre cada una no puede ser la misma, porque su papel en el modelo no es el mismo [13], así que se resolvió variable por variable:

- **Headline:** se **elimina la fila**. Sin titular no hay texto que clasificar, y rellenarlo equivaldría a inventar la entrada del modelo.
- **Sentiment:** se rellena con la categoría **Unknown**. Al ser categórica, la ausencia puede tratarse como un nivel más y conservar el registro completo en lugar de descartarlo.
- **Index_Change_Percent:** se rellena con la **mediana**, más robusta que la media ante los valores extremos de una variable acotada entre -5 y $+5$.
- **News_Url:** irrelevante, y la columna entera se descarta antes de tratar nulos.

Tras eliminar las cuatro columnas sin relación con el objetivo y aplicar estas reglas, el conjunto analítico queda en **2,876 registros y 8 columnas, sin ningún valor faltante**.

2.3. Recodificación de la variable objetivo

La variable objetivo original tiene tres niveles repartidos casi en tercios. Para el modelo se agrupan **Medium** y **Low** en una sola categoría y se conserva **High** como categoría independiente, de modo que el problema pasa a ser binario: distinguir las noticias de **impacto alto** de las de **impacto medio o bajo**. La razón es operativa: desde el punto de vista de quien invierte, lo que importa es detectar la noticia que va a mover el mercado, y la distinción entre impacto medio y bajo no cambia la decisión.

2.4. Representación del texto

El modelo multinomial necesita que cada documento sea un vector de conteos sobre un vocabulario fijo [4]. La construcción de esa representación sigue tres pasos.

Primero la **tokenización**. La función `unnest_tokens()` separa cada titular en palabras, una por renglón, y de paso las convierte a minúsculas. A cada titular se le asigna antes un identificador, para poder relacionar cada palabra con el documento del que salió y con su etiqueta.

Después la **eliminación de palabras vacías**, mediante un `anti_join` contra el conjunto

stop_words que incluye **tidytext**. Son términos como artículos, preposiciones y auxiliares que aparecen con altísima frecuencia y no ayudan a separar clases; su presencia solo agrega columnas ruidosas al vocabulario.

Por último la **matriz documento–término**. Se cuenta cuántas veces aparece cada palabra dentro de cada titular y el resultado se convierte con **cast_sparse()** en una matriz dispersa en la que cada renglón es un titular, cada columna una palabra del vocabulario y cada celda el número de apariciones. El formato disperso es el adecuado porque la enorme mayoría de las celdas son ceros: ningún titular contiene más que un puñado de las palabras del vocabulario.

2.5. El clasificador naïve Bayes multinomial

Sea $c \in \{\text{alto, otro/bajo}\}$ la clase y $\mathbf{x} = (x_1, \dots, x_{|V|})$ el vector de conteos de un titular sobre un vocabulario V . El clasificador aplica la regla de Bayes y supone independencia condicional entre términos dada la clase, con lo que la probabilidad posterior queda, salvo una constante de normalización,

$$P(c | \mathbf{x}) \propto P(c) \prod_{w \in V} P(w | c)^{x_w}, \quad (1)$$

y la predicción es la clase que maximiza (1). Las probabilidades a priori $P(c)$ se estiman por la frecuencia relativa de cada clase en el entrenamiento, y las verosimilitudes de cada término por su frecuencia relativa dentro de la clase.

Esa última estimación necesita una corrección. Si una palabra del conjunto de prueba nunca apareció junto a una clase en el entrenamiento, su verosimilitud estimada es cero y, al multiplicarse en (1), anula la probabilidad de esa clase para todo el titular sin importar qué digan las demás palabras. El remedio estándar es el **suavizado de Laplace** [4], que añade una cuenta ficticia a cada término:

$$\hat{P}(w | c) = \frac{N_{wc} + \alpha}{\sum_{v \in V} N_{vc} + \alpha |V|}, \quad \alpha = 1, \quad (2)$$

donde N_{wc} es el número de veces que el término w aparece en documentos de la clase c . Con $\alpha = 1$ ninguna verosimilitud es exactamente cero y ninguna palabra desconocida puede vetar una clase por sí sola.

2.6. Partición y métricas

El conjunto se divide en **80 % de entrenamiento y 20 % de prueba** mediante un muestreo aleatorio de renglones con semilla fija, de modo que la partición sea reproducible. El ajuste se realiza con **naive_bayes()** [12], que requiere la matriz en formato denso, por lo que ambos conjuntos se convierten antes de entrenar.

La evaluación toma **Impacto Alto como clase positiva**, por ser la que interesa detectar. Sobre la matriz de confusión se calculan la exactitud, la precisión, la sensibilidad y su media armónica:

$$\text{Precisión} = \frac{TP}{TP + FP}, \quad \text{Sensibilidad} = \frac{TP}{TP + FN}, \quad (3)$$

$$F_1 = \frac{2 \text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}. \quad (4)$$

La exactitud por sí sola no basta como criterio, porque con clases desbalanceadas un clasificador que siempre responda la clase mayoritaria la obtiene alta sin haber aprendido nada; por eso se reporta también esa **línea base trivial** como referencia obligada.

3. Aplicación y resultados

3.1. Qué contiene el conjunto

La variable objetivo está prácticamente balanceada en su versión original: 1,039 noticias de impacto medio, 1,020 de impacto bajo y 965 de impacto alto, es decir cerca de un tercio cada

una. No hace falta, por tanto, ningún procedimiento de balanceo de clases. El sentimiento se reparte de la misma manera —974 noticias negativas, 951 neutrales y 928 positivas—, como muestra la Fig. 2. Los indicadores numéricos tampoco presentan nada anómalo: el cambio porcentual del índice se reparte de forma casi simétrica en su rango de -5 a $+5$, con mediana -0.10 , y el volumen operado cubre de forma uniforme el intervalo de 1 a 500 millones, con mediana 244.




Figura 2: Distribución de la variable objetivo (izquierda) y del sentimiento (derecha). Las tres categorías de `Impact_Level` y los tres valores de `Sentiment` tienen frecuencias casi idénticas; las 171 noticias sin sentimiento registrado no aparecen en el panel derecho.

Tras la recodificación binaria, el conjunto queda con **918 noticias de impacto alto (31.9 %)** y **1,958 de impacto medio o bajo (68.1 %)**. Las clases no quedan en 50/50, pero el desbalance es moderado y manejable. Ese 68.1 % es, además, el número contra el que habrá que comparar cualquier resultado: es lo que acertaría un clasificador que respondiera siempre “impacto medio o bajo”.

3.2. El diagnóstico del análisis exploratorio

La exploración del texto arroja el hallazgo que condiciona todo lo demás. En las 3,024 filas hay únicamente **50 titulares distintos**, cada uno repetido en promedio 57.5 veces —entre 40 y 82 según el caso—, con una extensión media de apenas 8 palabras. El vocabulario disponible para el clasificador es, en consecuencia, diminuto.

Más grave es lo que ocurre con las etiquetas. **Un mismo titular aparece con los tres niveles de impacto**, y también con sentimientos y sectores distintos. Eso significa que el texto no determina la etiqueta ni siquiera de forma aproximada, y permite calcular un techo: si a cada titular se le asignara su nivel de impacto más frecuente —la mejor regla posible que use únicamente el titular—, se acertaría el **41.0 %** de las veces, contra el 34.4 % de adivinar siempre la clase mayoritaria. Siete puntos porcentuales es todo lo que el texto aporta.

El resto de las variables tampoco discrimina. La Tabla 2 muestra la proporción de cada nivel de impacto dentro de cada sentimiento y las medias de los dos indicadores numéricos por nivel: las distribuciones son prácticamente idénticas en los tres casos. Una noticia de sentimiento negativo tiene la misma probabilidad de ser de impacto alto que una de sentimiento positivo, y el cambio porcentual del índice asociado a las noticias de impacto alto no se distingue del de las de impacto bajo.

Tabla 2: Ausencia de relación entre el nivel de impacto y el resto de las variables. Arriba, la proporción de cada nivel dentro de cada sentimiento; abajo, la media de los indicadores numéricos por nivel.

Sentimiento	Low	Medium	High
Negative	0.339	0.337	0.324
Neutral	0.331	0.353	0.315
Positive	0.345	0.334	0.321

Nivel de impacto	Cambio del índice (%)	Volumen (millones)
Low	−0.04	252.0
Medium	+0.04	253.4
High	−0.07	241.2

La Fig. 3 lo muestra de forma más elocuente que la tabla: las cajas de los tres niveles de impacto se superponen casi por completo, tanto en el cambio porcentual del índice como en el volumen operado. Si el nivel de impacto describiera algo real del comportamiento del mercado, la caja de las noticias de impacto alto debería estar desplazada respecto de las otras dos —más dispersa en el cambio del índice, más alta en volumen—, y no lo está.




Figura 3: Cambio porcentual del índice (izquierda) y volumen operado (derecha) según el nivel de impacto declarado. Las tres distribuciones son indistinguibles entre sí, incluida la de las noticias de impacto alto.

La lectura conjunta de estos tres hechos —titulares repetidos, etiquetas contradictorias para el mismo texto y ausencia de relación con las demás variables— apunta a que el conjunto es **sintético y sus etiquetas fueron asignadas de forma esencialmente aleatoria**. La consecuencia práctica es que conviene esperar un desempeño modesto del clasificador, y que un desempeño modesto no debe interpretarse como una falla del método.

3.3. La matriz documento–término

Después de tokenizar y eliminar las palabras vacías, los términos más frecuentes son los que cabría esperar de titulares financieros —*market*, *sector*, *stocks*, *trade*, *investors*—, lo que confirma que la limpieza conservó vocabulario con contenido y no residuos gramaticales.

La matriz resultante tiene **2,876 renglones y 238 columnas**, con **18,248 entradas distintas de cero**, es decir una densidad de **2.67 %**. Un vocabulario de 238 términos es muy pequeño para clasificación de texto, y es la traducción directa de tener solo 50 titulares distintos de ocho palabras cada uno. El vector de etiquetas tiene la misma longitud que el número de renglones y está ordenado por el mismo identificador, de modo que cada fila conserva su etiqueta.

3.4. Entrenamiento y resultados

La partición deja **2,301 registros de entrenamiento y 575 de prueba**, con proporciones de clase similares entre ambos, de modo que el muestreo aleatorio no introdujo un desbalance adicional. La Tabla 3 presenta la matriz de confusión sobre el conjunto de prueba y la Tabla 4 las métricas que se derivan de ella.

Tabla 3: Matriz de confusión sobre el conjunto de prueba ($n = 575$).

Real	Predicho		Total
	Impacto Alto	Impacto Otro/Bajo	
Impacto Alto	86	95	181
Impacto Otro/Bajo	172	222	394
Total	258	317	575

Tabla 4: Métricas de desempeño, tomando Impacto Alto como clase positiva.

Métrica	Valor	Referencia
Exactitud	0.536	Línea base (clase mayoritaria): 0.685
Precisión	0.333	Azar bajo la proporción de la clase: 0.315
Sensibilidad	0.475	—
F_1	0.392	—

El modelo alcanza una exactitud de **53.6 %**, **por debajo del 68.5 %** que se obtendría prediciendo siempre la clase mayoritaria. No es solo que aprenda poco: en términos de exactitud, aplicarlo es peor que no tener modelo. La precisión de 33.3 % apenas se distingue de la proporción de noticias de impacto alto en el conjunto de prueba, que es lo que obtendría un clasificador que lanzara alertas al azar. La sensibilidad de 47.5 % completa el cuadro: el modelo se comporta, en la práctica, como si estuviera decidiendo por sorteo.

3.5. Interpretación en el contexto financiero

Las dos formas de equivocarse tienen costos distintos para quien invierte, y conviene traducirlas.

Falsas alarmas. El modelo emite 258 alertas de impacto alto y solo 86 son correctas: de cada tres alertas, dos son falsas. Un inversionista que actuara sobre cada una estaría cubriéndose, vendiendo o reposicionándose ante noticias que no iban a mover el mercado, y pagaría comisiones y fricción casi el doble de veces de las que acertaría. Más allá del costo directo, una señal que se equivoca dos de cada tres veces pierde credibilidad y deja de usarse.

Oportunidades perdidas. De las 181 noticias de impacto alto que realmente ocurrieron en el conjunto de prueba, 95 —el 52.5 %— quedaron clasificadas como impacto medio o bajo. Más de la mitad de las noticias relevantes pasan desapercibidas, lo que deja al inversionista sin cobertura frente a movimientos reales del mercado justamente cuando la necesitaría.

Con este desempeño el modelo no es utilizable en ninguno de los dos extremos: no sirve como sistema de alerta, porque satura de falsos positivos, ni como filtro de tranquilidad, porque deja pasar la mitad de lo importante. Y conviene subrayar de dónde viene el problema. Un clasificador cuyo techo, usando el texto disponible, es del 41 % en la tarea de tres clases no puede rendir mucho más; el ruido en las etiquetas acota el desempeño alcanzable con independencia del algoritmo [7], y ninguna elección de modelo recupera información que los datos no contienen. Cambiar naïve Bayes por un método más sofisticado no cambiaría el diagnóstico: el error irreducible del problema, tal como está planteado, es demasiado alto [14].

3.6. Limitaciones

El conjunto no permite aprender. Es la limitación dominante y no es del método: 50 titulares distintos, cada uno repetido decenas de veces y etiquetado de forma inconsistente, dejan al clasificador sin señal que extraer. Los resultados de este trabajo describen ese conjunto, no la capacidad de naïve Bayes para clasificar noticias financieras en general.

Falta de documentación del origen de los datos. No se dispone de información sobre cómo se generaron las noticias ni sobre cómo se asignaron las etiquetas de impacto, que es justamente lo que permitiría confirmar la sospecha de que el conjunto es sintético. La práctica de acompañar cada conjunto con una ficha que documente su procedencia y su proceso de etiquetado existe precisamente para evitar este tipo de ambigüedad [15].

Supuesto de independencia sobre titulares muy cortos. Con una media de ocho palabras por titular, y tras eliminar las vacías, quedan pocos términos por documento; el supuesto de independencia condicional se vuelve más frágil cuando cada palabra pesa mucho en el producto de (1).

Una sola partición. Las métricas provienen de una única división en entrenamiento y prueba. Un esquema de validación cruzada daría una estimación más estable, aunque con este nivel de desempeño la conclusión difícilmente cambiaría.

Solo se usó el texto. El modelo se entrena únicamente con la matriz de titulares; el sentimiento, el sector, el evento de mercado y los indicadores numéricos se conservaron en el conjunto analítico pero no entraron al clasificador. El análisis exploratorio sugiere que incorporarlos no habría ayudado, ya que ninguno discrimina entre niveles de impacto, pero eso no se verificó ajustando un modelo con ellos.

4. Conclusiones

El trabajo se planteó una pregunta directa: si un clasificador naïve Bayes multinomial puede decidir, a partir del titular, si una noticia financiera va a mover el mercado de forma apreciable. La respuesta, para el conjunto analizado, es que no. El modelo se comporta peor que la regla trivial de responder siempre la categoría más común, emite bastantes más alertas falsas que correctas y deja pasar más de la mitad de las noticias que sí eran relevantes, de modo que no sirve ni como sistema de aviso ni como filtro de tranquilidad. Un inversionista que actuara sobre sus señales pagaría fricción por operaciones innecesarias y, al mismo tiempo, quedaría sin cobertura frente a buena parte de los movimientos reales.

Lo interesante es que ese resultado estaba anunciado antes de entrenar nada. La exploración de los datos mostró que el conjunto contiene muy pocos titulares distintos, repetidos muchas veces, y que un mismo titular aparece etiquetado con todos los niveles de impacto; que el sentimiento no distingue unas noticias de otras; y que los indicadores del índice y del volumen se distribuyen igual sin importar el impacto declarado. Con esas tres observaciones sobre la mesa, la mejor regla concebible que use solamente el texto apenas mejora al azar, y ningún clasificador puede superar un techo que fijan los datos y no el algoritmo. La conclusión metodológica es más valiosa que la métrica: cuando el desempeño es bajo conviene averiguar si el problema está en el modelo o en el conjunto antes de cambiar de método, porque en el segundo caso ningún cambio de método ayuda.

Al mismo tiempo, el flujo construido sí cumplió su función. Las decisiones de limpieza se tomaron variable por variable y quedaron escritas, la recodificación de la variable objetivo respondió a una lógica operativa —lo que le importa a quien invierte es separar lo que mueve el mercado de lo que no—, la representación del texto siguió el camino habitual de tokenizar, descartar palabras vacías y construir una matriz dispersa de conteos, y el suavizado evitó que una palabra desconocida anulara una clase entera. Ese andamiaje es reutilizable tal cual, y esa es la parte del trabajo que sobrevive al conjunto de datos con el que se probó.

De cara a lo que sigue, el camino evidente es sustituir la fuente por titulares reales y variados, con etiquetas de impacto derivadas del comportamiento observado del índice en lugar de asignadas de antemano; con eso el mismo flujo produciría una evaluación informativa, favorable o no. Sobre esa base tendría sentido incorporar al clasificador las variables que aquí se conservaron pero no se usaron, comparar la representación de conteos contra alternativas que ponderen los términos por su capacidad de discriminar, y sustituir la partición única por validación cruzada para que las métricas vengan con una medida de su variabilidad. Ninguna de esas mejoras tiene sentido, sin embargo, mientras las etiquetas no guarden relación con el texto: la primera tarea de cualquier continuación es conseguir datos que sí contengan la señal que se pretende aprender.

Referencias

- [1] Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, 62(3), 1139–1168.
- [2] Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65.
- [3] Antweiler, W., & Frank, M. Z. (2004). Is all that talk just noise? The information content of internet stock message boards. *The Journal of Finance*, 59(3), 1259–1294.
- [4] Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge: Cambridge University Press.
- [5] McCallum, A., & Nigam, K. (1998). A comparison of event models for naive Bayes text classification. En *AAAI-98 Workshop on Learning for Text Categorization*, 41–48.
- [6] Domingos, P., & Pazzani, M. (1997). On the optimality of the simple Bayesian classifier under zero-one loss. *Machine Learning*, 29(2–3), 103–130.
- [7] Frénay, B., & Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5), 845–869.
- [8] McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference*, 56–61.
- [9] R Core Team (2024). *R: A Language and Environment for Statistical Computing*. Viena: R Foundation for Statistical Computing.
- [10] Wickham, H., et al. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686.
- [11] Silge, J., & Robinson, D. (2016). tidytext: Text mining and analysis using tidy data principles in R. *Journal of Open Source Software*, 1(3), 37.
- [12] Majka, M. (2019). *naivebayes: High Performance Implementation of the Naive Bayes Algorithm in R*. Paquete de R.
- [13] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.
- [14] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2a ed.). Nueva York: Springer.
- [15] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92.